

פרק 3
2.35782-8

1.1

(a) (1)

$$TPR = \mathbb{P}_D(h_t(x) = 1 | y = 1) = \frac{\sum_{i=1}^n \mathbb{P}(y_i = 1 \wedge h_t(x_i) = 1)}{\sum_{i=1}^n \mathbb{P}(y_i = 1)} = \mathbb{P}(h_t(x_i) = 1)$$

\uparrow \uparrow
 הנתון h
 הנתון y

$$\mathbb{P}(h_t(x_i) = 1) = \mathbb{P}(z_i \geq t) = 1 - t$$

h_t \rightarrow z_i

$$|t - 1 - p|$$

TPR = p

(b) כמות $1 - p$ של נקודות:

$$FPR = \frac{\sum_{i=1}^n \mathbb{P}(y_i = 0, h_t(x_i) = 1)}{\sum_{i=1}^n \mathbb{P}(y_i = 0)} = \mathbb{P}(h_t(x_i) = 1) = p$$

\uparrow
 הנתון

הוא, במקרה זה $FPR = TPR$, קו-ליניאריות, היותו של ציר
הנתונים וזהו המרחב אחיד.

(2) $\Sigma \in \mathbb{R}^{d \times d}$ מרחב סגור סגור

$$u^T \Sigma u = u^T \sum_{i=1}^d \sigma_i v_i v_i^T u = \sum_{i=1}^d \sigma_i u^T v_i v_i^T u = \sum_{i=1}^d \sigma_i (v_i^T u)(v_i^T u) = \sum_{i=1}^d \sigma_i (v_i^T u)^2 \geq 0$$

\downarrow \downarrow
 ו \downarrow

$\Sigma \in \mathbb{R}^{d \times d}$ מרחב סגור, $u \in \mathbb{R}^d$ וקטור, $u^T \Sigma u \geq 0$

הפונקציה, נבחר $u = v_i$, ונקבל:

$$\sum_{i=1}^d \sigma_i (u^T v_i v_i^T u) = \sum_{i=1}^d \sigma_i (v_i^T v_i) (v_i^T v_i)$$

הערות, אם σ_i eigenvalue, $\sigma_i \geq 0$ נקרא σ_i ערכים
 $u^T \Sigma u = \sum_{i=1}^d \sigma_i u_i^2 = \sigma_i < 0 \Rightarrow$ σ_i שלילי

σ_i \rightarrow σ_i eigenvalues \rightarrow σ_i \rightarrow σ_i

3) $N(0, \Sigma)$ \sim $N(0, \Sigma)$ \sim $N(0, \Sigma)$

$$p(x) = \det(2\pi\Sigma)^{-0.5} \cdot \exp\left[-\frac{1}{2}x^T \Sigma^{-1}x\right]$$

$$x^T \Sigma^{-1}x = \sum_{i=1}^d \lambda_i^{-1} x_i^2, \quad \lambda_i > 0 \quad \forall i$$

$$C = p(x)$$

$$C = \det(2\pi\Sigma)^{-0.5} \cdot \exp\left(-\frac{1}{2}x^T \Sigma^{-1}x\right) \Rightarrow -2 \log(C \cdot \det(2\pi\Sigma)^{0.5}) = \sum_{i=1}^d \lambda_i^{-1} x_i^2$$

$$\Rightarrow 1 = \sum_{i=1}^d \frac{x_i^2}{-2\lambda_i^{-1} \log(C \cdot \det(2\pi\Sigma)^{0.5})}$$

$$\text{וקרוב משווה } \Sigma \text{ (המטריצה)} \quad \text{המטריצה } \Sigma \text{ (המטריצה)}$$

$$4) \quad \text{kernel}$$

$$\langle \psi(x), \psi(x') \rangle = \sum_{j \in [d]} k \prod_{i=1}^k X_{j_i} \cdot X'_{j_i}$$

ההצגה שקורה ψ היא המטריצה Σ בהכרח Σ המטריצה Σ $\alpha=1$ k מספרים

$$\sum_{j=1}^d k_j = d \left(\begin{matrix} n \\ k_1, k_2, \dots, k_d \end{matrix} \right) \prod_{t=1}^d (x_{t+1} \cdot x'_t)^{k_t}$$

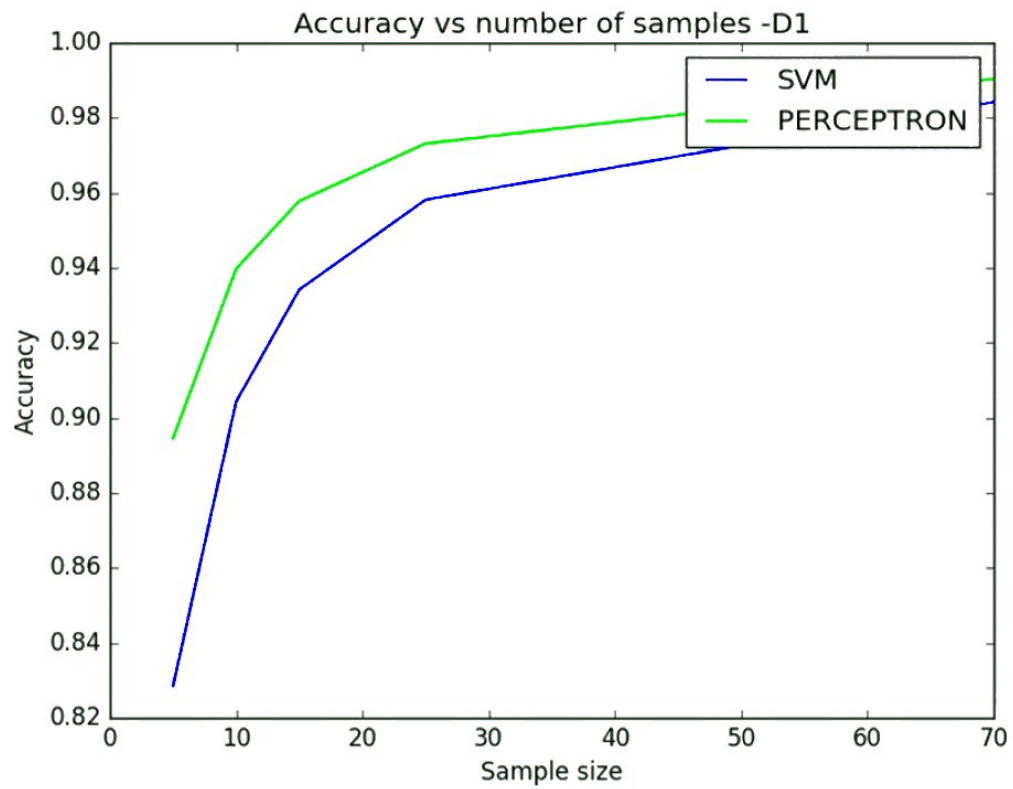
$$\text{אם } \Sigma \text{ הוא מטריצה } \langle x, x' \rangle^k$$

$$\langle \psi(x), \psi(x') \rangle = \langle x, x' \rangle^k$$


סיום

Perceptron vs SVM (See code on Perceptron.py)

Graph 1: Perceptron vs Svm – accuracy as a function of training size on normal Dist.



Graph 2 : Perceptron vs SVM – accuracy as a function of training size on Rectangle Dist.




הסבר: נשים לב כי כשדוגמים מהריבועים (ההתפלגות השניה, גרף 2) יש מישור מפריד ברור בין הדגימות, ואולם בדגימות המתקבלות מהגאוסיאן (גרף 1) הואיל והדגימות צפופות ורצופות יותר, קשה יותר למצוא את הקו הספציפי שמפריד, ולכן לפרספטרון היה "קל" יותר למצוא קו מפריד בדגימות שהתקבלו מהגאוסיאן, הואיל וכל דגימה חדשה שינתה אותו במעט, כך שבקירוב, ככל שאלגוריתם הפרספטרון דוגם מחדש מאותו מדגם ומבצע התאמה ושקלול מספר רב של פעמים, אזי מידת הדיוק שלו תגדל במציאת הקו המפריד. לעומתו, אלגוריתם ה-SVM ינסה למקסם את השוליים ללא הצלחה, עקב המרחק הקטן בין הדגימות ולכן ביצועיו יהיו פחות מוצלחים בגרף השני, ברור כי הפרספטרון משמעותית מציג תוצאות פחות טובות מבחינת הדיוק עקב המרחק הרב בין הדגימות, כלומר, כל דגימה חדשה שתתקבל, הפרספטרון יתאים את עצמו אליה (הולך אחרי הרעש) ולכן לא מתמודד טוב עם דגימות חדשות

שאלה 8:

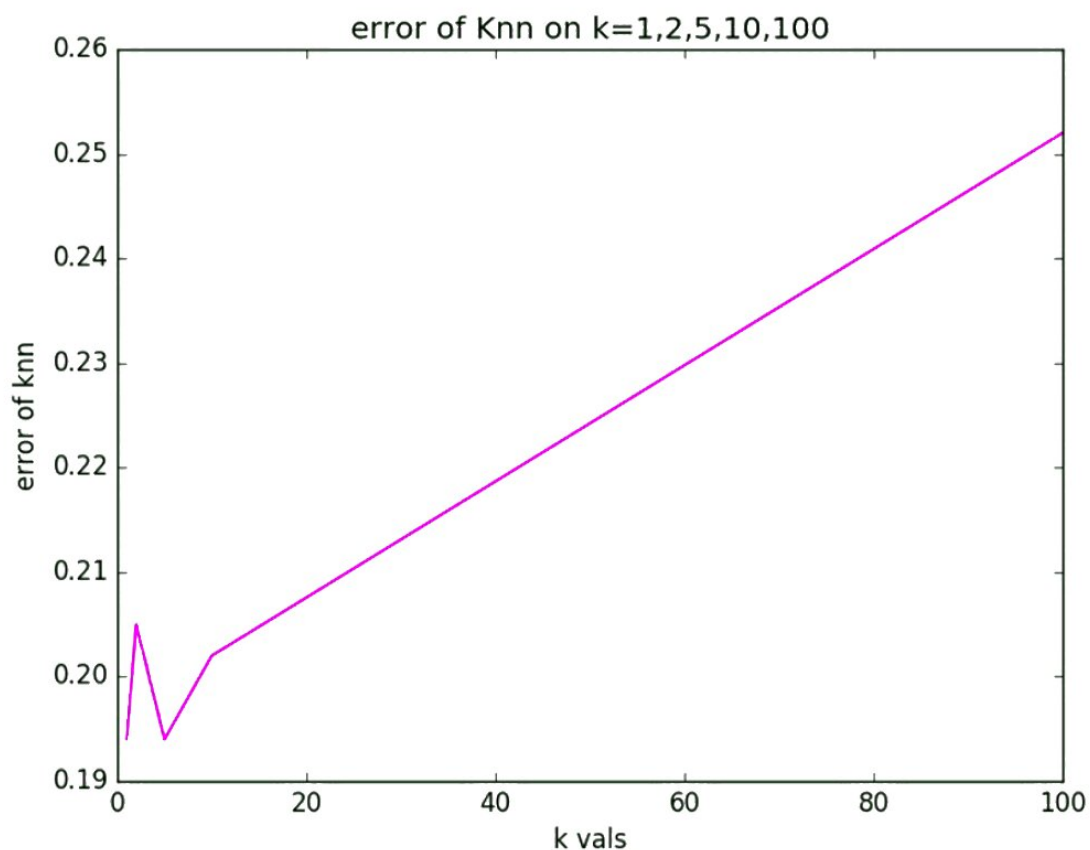
(a , b) ROC- Curve for Logistic Regression

Graph 3: TPR vs FPR (Code on ROC.py)



(c) K-nearest neighbors : See code on file knn.py

Graph 4 : K nearest – neighbors : Accuracy as a function of k



ניתן להבחין מהגרף כי עבור מספר שכנים קטן יותר נקבל את התוצאות הטובות ביותר, כלומר עלינו לקבל מידע מוקדם על אופי ההפלגות והדגימות כדי שנוכל לקבוע מהם השכנים הטובים ביותר לצורך הקלסיפיקציה, כלומר אלגוריתם כפי שמימשנו מכיל רעש רב ויתכן כי במקרים מסוימים יבחר את אותם הנקודות אך ילך אחר הרעש כשיקבל דגימה חדשה, רחוקה מהשתיים הנ"ל.